

# Polymarket

Documentação técnica e guia de estudo — SBGR, SAEZ, UUWW e mais

Pipeline `tmax/` — mercados de temperatura na Polymarket

Números do backtest atualizados em 2026-08-04 09:15:09 UTC

## Resumo

Este documento descreve, com a matemática e a estatística por trás, como o pipeline transforma previsões meteorológicas em decisões de trade em mercados binários de temperatura máxima, e como validamos essas decisões com backtests. É também um guia de estudo: cada seção termina com exercícios (gabarito no apêndice). **Não é aconselhamento financeiro** — mercados de previsão envolvem risco de perda total do capital, e o *edge* estimado aqui é um modelo, não uma garantia.

## Sumário

|          |                                                                        |          |
|----------|------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Visão geral</b>                                                     | <b>2</b> |
| <b>2</b> | <b>Da previsão à distribuição</b>                                      | <b>2</b> |
| 2.1      | Por que ensemble . . . . .                                             | 2        |
| 2.2      | Correção de viés ( <code>bias.py</code> ) . . . . .                    | 2        |
| 2.3      | Nowcast intradiário . . . . .                                          | 2        |
| 2.4      | Mistura de gaussianas . . . . .                                        | 3        |
| <b>3</b> | <b>Do modelo ao mercado</b>                                            | <b>3</b> |
| 3.1      | Faixas, arredondamento e unidades . . . . .                            | 3        |
| 3.2      | Edge e valor esperado . . . . .                                        | 3        |
| <b>4</b> | <b>Calibração — o coração estatístico</b>                              | <b>4</b> |
| 4.1      | Regressão isotônica (PAVA) . . . . .                                   | 4        |
| 4.2      | O <i>blend</i> com o preço (diagnóstico) . . . . .                     | 4        |
| <b>5</b> | <b>Estratégias operacionais</b>                                        | <b>4</b> |
| 5.1      | Estratégia <i>Edge</i> . . . . .                                       | 4        |
| 5.2      | Estratégia <i>Colheita de favoritos</i> . . . . .                      | 4        |
| 5.3      | Stop loss . . . . .                                                    | 5        |
| 5.4      | Como os alertas chegam ao vivo (produção) . . . . .                    | 5        |
| <b>6</b> | <b>Backtest — metodologia e resultados atuais</b>                      | <b>5</b> |
| 6.1      | Metodologia . . . . .                                                  | 5        |
| 6.2      | Resultados (arquivo de 4154 dias-cidade, ~107 dias corridos) . . . . . | 6        |
| <b>7</b> | <b>Gestão de risco</b>                                                 | <b>6</b> |
| <b>A</b> | <b>Gabarito</b>                                                        | <b>6</b> |

## 1 Visão geral

O objetivo é comparar, para cada faixa de um mercado do tipo “a máxima de hoje vai ser  $N^\circ\text{C}^\circ$ ”, a nossa probabilidade estimada com a probabilidade implícita pelo preço, e agir quando as duas divergem o suficiente e o modelo está calibradamente confiante.

O sistema tem três camadas:

1. **Previsão** (Seção 2): ensembles numéricos + correção de viés + observações em tempo real → uma *distribuição de probabilidade* da máxima do dia.
2. **Precificação e calibração** (Seções 3 e 4): a distribuição vira probabilidade por faixa de mercado, corrigida por uma curva de calibração empírica.
3. **Estratégia e risco** (Seções 5 e 7): quando comprar, quanto apostar, quando sair.

Hoje o sistema é *somente-leitura*: monitora 39 cidades, manda alertas ao Telegram e mede tudo com backtests; a ordem na Polymarket é executada manualmente. Estações que resolvem em Fahrenheit foram catalogadas mas ficam fora de operação.

**Exercício 1.1.** Num binário, o preço do “Sim” (entre 0 e 1) é interpretado como a probabilidade que o mercado atribui ao evento. Se o “Sim” custa \$0,40, qual a probabilidade implícita do “Não”?

## 2 Da previsão à distribuição

### 2.1 Por que ensemble

Um modelo de tempo é um sistema caótico: erros minúsculos na condição inicial crescem exponencialmente. Um *ensemble* roda o mesmo modelo várias vezes com perturbações na condição inicial (ECMWF ENS: 51 membros; GEFS: 31). Cada membro é uma amostra do futuro possível; a fração de membros acima de um limiar estima a probabilidade de excedê-lo. Usamos ~82 membros.

### 2.2 Correção de viés (bias.py)

Modelos globais têm erro sistemático num ponto específico. Estimamos, por família de modelo  $m$ , ao longo dos últimos 60 dias:

$$\text{viés}_m = \frac{1}{n} \sum_{d=1}^n [\hat{T}_m(d) - T_{\text{obs}}(d)], \quad n \geq 15, \quad (1)$$

$$\sigma_m^{\text{res}} = \sqrt{\frac{1}{n-1} \sum_{d=1}^n [\hat{T}_m(d) - T_{\text{obs}}(d) - \text{viés}_m]^2}. \quad (2)$$

A previsão corrigida é  $\hat{T}_m - \text{viés}_m$ ; o desvio residual  $\sigma_m^{\text{res}}$  é o erro que *sobra* e vira o  $\sigma$  do membro na mistura (Seção 2.4).

### 2.3 Nowcast intradiário

Durante o dia, o observado pesa mais que o modelo. Medimos o desvio médio entre o METAR e a média do ensemble corrigido nas últimas 3 horas e deslocamos as horas restantes por uma fração amortecida:

$$\text{offset} = \text{mean}_{\text{últ. 3h}} [T_{\text{obs}}(h) - \bar{T}_{\text{ens}}^{\text{corr}}(h)], \quad \text{shift} = 0,7 \cdot w(h) \cdot \text{offset}, \quad (3)$$

com  $w(h) = \text{clamp}(\frac{h-6}{6}, 0,25, 1)$ . O fator 0,7 evita perseguir ruído;  $w(h)$  reduz o peso da madrugada, quando nevoeiro e inversão térmica enganam.

## 2.4 Mistura de gaussianas

Para cada membro  $i$ , a máxima corrigida do dia é  $\hat{T}_i = \max(\text{obs\_max}, \max_h[\text{horas futuras corrigidas}] + \text{shift})$ . A distribuição da máxima é a *média* das CDFs (mistura com pesos iguais):

$$F(x) = \Pr(T_{\max} \leq x) = \frac{1}{M} \sum_{i=1}^M \Phi\left(\frac{x - \hat{T}_i}{\sigma_i}\right), \quad \sigma_i = \max(\sigma_{\text{fam}(i)}^{\text{res}} \cdot f_{\text{rest}}, 0, 3), \quad (4)$$

com  $f_{\text{rest}} = \text{clamp}(\frac{17-h}{12}, 0, 2, 1)$  — a incerteza encolhe à tarde. Duas cirurgias que os backtests motivaram:

- **Truncagem:**  $F(x) = 0$  para  $x < \text{obs\_max}$  — a máxima nunca fica abaixo do já observado.
- **Trava:** quando o pico *observado* já passou (3 horas seguidas abaixo da máxima) e nenhuma hora futura chega perto,  $\sigma_i$  colapsa para 0,05. Exige a trava *observacional* — colapsar por previsão (o ensemble “achando” que a tarde não esquenta) gerava certezas falsas de manhã.

Os quantis (P10/P50/P90) saem por bissecção sobre  $F$ .

**Exercício 2.1.** O viés do ECMWF em Guarulhos é  $-0,7^\circ\text{C}$  e o modelo prevê máxima de  $24,0^\circ\text{C}$ . Qual a previsão corrigida? Se  $\sigma^{\text{res}} = 0,9$  e  $f_{\text{rest}} = 1$ , qual o  $\sigma$  do membro? **Exercício 2.2.**

Mistura de dois membros,  $\mathcal{N}(25, 1)$  e  $\mathcal{N}(27, 1)$ . Calcule  $\Pr(T_{\max} \leq 26)$  usando  $\Phi(1) = 0,841$  e  $\Phi(-1) = 0,159$ .

## 3 Do modelo ao mercado

### 3.1 Faixas, arredondamento e unidades

O mercado resolve pela máxima *arredondada ao inteiro* na unidade da cidade. A faixa “ $N^\circ\text{C}$ ” cobre  $[N - 0,5, N + 0,5)$ ; “entre  $A-B^\circ\text{F}$ ” cobre  $[A - 0,5, B + 0,5)$  em Fahrenheit. Como a distribuição interna é em  $^\circ\text{C}$ , faixas em  $^\circ\text{F}$  são convertidas nas *bordas*:  $c(f) = (f - 32) \cdot 5/9$ . A probabilidade da faixa  $[A, B]$  é

$$\Pr(\text{Sim}) = F(c(B + 0,5)) - F(c(A - 0,5)). \quad (5)$$

### 3.2 Edge e valor esperado

Num binário, o preço do Sim é a probabilidade implícita  $q$ . Pagando  $q$  num evento com probabilidade real  $p$ :

$$\text{EV por \$1} = p \cdot \left(\frac{1}{q} - 1\right) - (1 - p) = \frac{p - q}{q}. \quad (6)$$

O *edge* em pontos percentuais é  $p - q$ . O EV relativo cresce quando  $q$  é pequeno — por isso “bilhetes de loteria” baratos dominam o P&L de backtests ingênuos e merecem desconfiança (preço fino não executa).

**Exercício 3.1.** Mercado NYC “entre  $78-79^\circ\text{F}$ ”. Converta as bordas da faixa para  $^\circ\text{C}$ . **Exercício**

**3.2.** Você compra o “Não” a  $\$0,85$  e sua probabilidade calibrada do “Não” é 94%. Calcule o edge (p.p.) e o EV por  $\$1$ .

## 4 Calibração — o coração estatístico

Um modelo é *calibrado* se, entre os casos em que diz 90%, o evento ocorre  $\sim 90\%$  das vezes. Medimos com o *Brier score* (erro quadrático médio da probabilidade; menor é melhor):

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2, \quad y_i \in \{0, 1\}. \quad (7)$$

Diagnóstico sobre  $\sim 120$  mil pares previsão–desfecho: o modelo cru declara  $\sim 99\%$  mas acerta entre 85% e 93% nas faixas-dia com confiança  $\geq 90\%$  (varia por cidade) — superconfiança nas caudas.

### 4.1 Regressão isotônica (PAVA)

Ajustamos  $g$  monótona não-decrescente minimizando  $\sum (g(p_i) - y_i)^2$  pelo algoritmo *Pool Adjacent Violators*: percorre os pares ordenados por  $p$  e funde blocos vizinhos enquanto a média de um bloco anterior for  $\geq$  à do seguinte. Resultado: um mapa “probabilidade dita  $\rightarrow$  frequência real”, por *período do dia* (0–5h / 6–11h / 12–23h), porque a superconfiança da madrugada (pouca observação) é muito maior que a da tarde.

### 4.2 O *blend* com o preço (diagnóstico)

Uma regressão logística  $y \sim a \text{logit}(p_{\text{modelo}}) + b \text{logit}(\text{preço}) + c$ , por período, mede quem carrega informação: de madrugada  $a \approx 0$  (o modelo não adiciona nada ao preço); à tarde  $a > 0$  (adiciona). Decisão operacional: os sinais usam só o modelo calibrado (o mesmo número da tabela); o *blend* segue como diagnóstico.

**Exercício 4.1.** O modelo declara 99% em 842 faixas-dia e acerta 86%. Qual o Brier aproximado dessas previsões? (aproxime  $p = 0,99$  e frequência 0,86.) **Exercício 4.2.** PAVA: pares ordenados

por  $p$  com desfechos  $y = [0, 1, 0, 1, 1]$ . Quais os blocos e os valores finais da isotônica?

## 5 Estratégias operacionais

### 5.1 Estratégia *Edge*

Compra o “Não” de uma faixa de hoje quando:

- $|p_{\text{cal}} - q| \geq 5$  p.p. (divergência mínima);
- o lado “Não” tem  $> 90\%$  de chance segundo o modelo calibrado;
- preço do “Não”  $\geq \$0,30$  (não brigar com mercado quase-certo);
- hora local entre 6h e 23h; cruzamento novo (madrugada é descartada).

Só o lado “Não” é operado: o “Sim” teve  $\sim 41\%$  de acerto (loteria). Testamos e *rejeitamos* um teto de *edge* de 20 p.p.: no lado “Não” já filtrado, gaps grandes são o modelo vendo a máxima da tarde antes do mercado convergir, não erro.

### 5.2 Estratégia *Colheita de favoritos*

Compra o “Não” quase-certo (preço entre  $\$0,97$  e  $\$0,995$ ), após as 16h locais, com o modelo concordando. Depois desse horário a máxima está praticamente travada e o favorito a 97 centavos é quase-matemática. Colhe os últimos centavos de incerteza residual.

### 5.3 Stop loss

Num binário o preço *é* a probabilidade: cair 15% significa que o mercado agora acha o evento 15% menos provável. O stop converte a perda potencial total (−100%) numa perda pequena e certa (−15%), ao custo de realizar ruído. Vale quando o gatilho é *informativo* (o dado virou — a máxima estourou a faixa) e custa caro quando é só volatilidade.

**Exercício 5.1.** Você entra a \$0,70; o alerta dispara a −10% e a saída do backtest a −15%. Em que preços cada um dispara? Se o evento venceria na resolução, quanto o stop custou por \$1 de stake?

### 5.4 Como os alertas chegam ao vivo (produção)

O backtest conta *entradas* (uma por faixa/dia, no primeiro cruzamento); o que chega ao Telegram segue regras de *entrega* diferentes:

- **Modo silencioso:** o chat recebe só alertas (compra, colheita, condição, stop) e o resumo de posições no máximo 1× por hora.
- **Alerta de compra novo:** chega com o *bloco completo* da cidade (tabela, gráfico, hora a hora) — o contexto da decisão de entrada. Você também pode pedir o relatório de qualquer cidade a qualquer momento por `/relatorio`.
- **Repetição:** *edge* e colheita repetem a cada rodada (~10 min) enquanto a oportunidade durar; as repetições vêm sozinhas em texto curto (sem repetir os gráficos). Uma entrada equivale a muitas mensagens.
- **Alertas de condição** (só cidades com posição aberta): platô de 2h de lado e fuga do envelope do *ensemble* — uma vez por episódio.
- **Stop:** dispara a −10% do preço de entrada e repete toda rodada; a saída de referência do backtest é −15%.

**Ao vivo dispara mais que o backtest.** O backtest só considera faixas com negócio recente ( $\leq 2h$ ); ao vivo o alerta usa o preço nominal exibido, e por isso também dispara em faixas ilíquidas que o backtest descarta. Medido no arquivo atual, são ~18% mais sinais ao vivo do que a simulação reporta — não é erro, são medições diferentes. Além disso, num único dia os sinais se *acumulam* no chat (cada cidade no seu fim de tarde local), enquanto o backtest os distribui por data: por isso um dia com 3–4 sinais parece muito, mas ainda é um evento raro (o histórico teve no máximo 4 num único dia).

## 6 Backtest — metodologia e resultados atuais

### 6.1 Metodologia

Para cada dia arquivado reconstruímos, hora a hora, o que o sistema atual teria dito: viés “como era” (janela de 60 dias terminando 2 dias antes), METARs até a hora  $h$ , ensemble arquivado, nowcast, mistura  $\rightarrow$  probabilidade por faixa; preço = último negócio (máx. 2h de idade); resolução = desfecho oficial. Aposta de 10% do capital no primeiro cruzamento da regra, liquidada na resolução (ou no stop de −15%). **Flat** usa sempre 10% do capital *inicial* (para comparar regras); **composto** reinveste 10% do capital *corrente* (o “quanto eu teria”).

**Vieses conhecidos.** *Lookahead* do ensemble arquivado (otimista); *liquidez* (o último preço de mercado fino não executa em tamanho); *in-sample* (a calibração é ajustada no mesmo período — mitigada pelo reajuste a cada 3 dias, com dias novos entrando *depois* do ajuste).

## 6.2 Resultados (arquivo de 4154 dias-cidade, ~107 dias corridos)

| Estratégia                             | Entradas    | Acerto     | Composto       | DD máx     | Stops     |
|----------------------------------------|-------------|------------|----------------|------------|-----------|
| Edge (Não, simulação histórica)        | 376         | 90%        | 47.91 x        | 22%        | 73        |
| Colheita 16h                           | 694         | 100%       | 1.85 x         | 3%         | 6         |
| Colheita 14h                           | 1311        | 99%        | 2.41 x         | 8%         | 23        |
| Colheita 12h                           | 1808        | 99%        | 2.90 x         | 9%         | 38        |
| <b>Combinado (Edge + Colheita 16h)</b> | <b>1070</b> | <b>96%</b> | <b>55.10 x</b> | <b>20%</b> | <b>79</b> |

Retorno composto do portfólio combinado, anualizando a janela de ~107 dias para base mensal: **+208% ao mês** (in-sample; a expectativa executada realista é mais modesta, tipicamente 10–20%/mês, por causa de liquidez e slippage). Preço médio pago pela Edge: \$0.83.

*Estes números são regenerados automaticamente a cada backtest (2026-08-04 09:15:09 UTC) — veja `backtest_results/` e `generated_numbers.tex`.*

**Exercício 6.1.** A estratégia Edge fez 376 entradas em ~107 dias. Isso é o número de alertas que você recebeu? Explique a diferença entre “entradas simuladas” e “mensagens recebidas”.

## 7 Gestão de risco

Kelly para um binário comprado a  $q$  com probabilidade real  $p$ :

$$f^* = \frac{p - q}{1 - q} \quad (\text{fração da banca; aposte } 0 \text{ se } p \leq q). \quad (8)$$

Kelly maximiza o crescimento logarítmico *mas* assume  $p$  exato — e a Seção 4 mostrou que nosso  $p$  tem erro. Regra da casa:  $\frac{1}{4}$  de Kelly, teto de 5% por mercado, 10–15% somando o dia/cidade (faixas do mesmo dia são *uma* aposta), e *circuit breaker* de drawdown mensal.

**Exercício 7.1.** Kelly:  $p = 0,90$ , preço  $q = 0,80$ . Calcule  $f^*$  e  $\frac{1}{4}$  de Kelly. Com banca de \$2.000, quanto apostar (respeitando o teto de 5%)?

## A Gabarito

**1.1**  $1 - 0,40 = 0,60 = 60\%$ .

**2.1**  $24,0 - (-0,7) = 24,7^\circ\text{C}$ ;  $\sigma = \max(0,9 \cdot 1; 0,3) = 0,9$ .

**2.2**  $F(26) = \frac{1}{2}[\Phi(1) + \Phi(-1)] = \frac{1}{2}(0,841 + 0,159) = 0,50$ .

**3.1**  $c(77,5) = (77,5 - 32) \cdot 5/9 = 25,28^\circ\text{C}$ ;  $c(79,5) = 26,39^\circ\text{C}$ . Faixa  $[25,28; 26,39]$ .

**3.2** Edge =  $94 - 85 = 9$  p.p.; EV =  $(0,94 - 0,85)/0,85 = +10,6\%$  por \$1.

**4.1** Brier  $\approx 0,86 \cdot (0,99 - 1)^2 + 0,14 \cdot (0,99 - 0)^2 \approx 0,137$  (contra  $\sim 0,01$  se calibrado).

**4.2**  $[1, 0]$  viola  $\rightarrow$  funde em 0,5. Valores finais: 0; 0,5; 0,5; 1; 1.

**5.1** Alerta a  $0,70 \cdot 0,90 = \$0,63$ ; saída a  $0,70 \cdot 0,85 = \$0,595$ . Num vencedor você recebeu 0,85 em vez de  $1/0,70 = 1,43$  por \$1 de stake  $\Rightarrow$  deixou  $\sim 0,58$  na mesa.

**6.1** NÃO é contagem de alertas. “Entradas simuladas” = quantas vezes a regra teria comprado reencenando o histórico; “mensagens recebidas” inclui as repetições a cada 10 min enquanto a oportunidade dura (uma oportunidade = muitas mensagens).

**7.1**  $f^* = (0,90 - 0,80)/(1 - 0,80) = 0,50$ ;  $\frac{1}{4}$  Kelly = 12,5%  $\Rightarrow$  \$250, mas o teto de 5% limita a \$100.